Optimización de Arquitecturas YOLOv11 para Vigilancia Urbana en Tiempo Real

Sebastian Arturo Acuña Concha
Universidad de Santiago de Chile (USACH)

***Resumen*—Este trabajo aborda el desafío del procesamiento de video en alta resolución (4K) para sistemas de vigilancia urbana mediante la optimización de arquitecturas YOLO11 en hardware NVIDIA Tesla T4. Partiendo de una línea base de 7.10 FPS en entornos nativos, se implementó una estrategia de optimización multiresolución y ajuste de *stride* que permitió alcanzar un rendimiento de 107.03 FPS en 640p, representando una mejora en la eficiencia operativa del 1,400 %. Los resultados finales del benchmarking consolidado demuestran que la solución propuesta opera con una latencia total de 39.85 ms (25.09 FPS), superando ampliamente el rendimiento reportado para arquitecturas de detección de dos etapas como Faster R-CNN, las cuales suelen operar por debajo de 1 FPS en escenarios de alta resolución según la literatura. Finalmente, se validó la versatilidad del sistema mediante la integración de un módulo de biometría facial (8.10 FPS), consolidando un marco de trabajo eficiente y reproducible para aplicaciones de seguridad ciudadana en tiempo real en el contexto de la USACH.**

I. Introducción

En la actualidad, la seguridad ciudadana y la vigilancia urbana inteligente demandan sistemas de monitoreo capaces de procesar flujos de video de alta resolución con latencias mínimas para permitir una respuesta inmediata ante incidentes. Sin embargo, la implementación de algoritmos de aprendizaje profundo (*Deep Learning*) en entornos de producción enfrenta un desafío crítico: el equilibrio entre la precisión de detección y el costo computacional.

Históricamente, arquitecturas como Faster R-CNN han sido el estándar en detección de objetos debido a su robustez; no obstante, su naturaleza de dos etapas las hace computacionalmente prohibitivas para aplicaciones en tiempo real, registrando rendimientos inferiores a 1 FPS en hardware de gama media. Por otro lado, la familia de modelos YOLO (*You Only Look Once*) ha revolucionado el área mediante una arquitectura de una sola etapa que optimiza el flujo de gradientes y las operaciones en la GPU.

El despliegue de video en resolución 4K nativa, si bien ofrece una fidelidad de detalle superior para la identificación forense, introduce un cuello de botella sistémico que degrada el rendimiento de modelos modernos como YOLO11 a niveles inviables, tales como la línea base de 7.10 FPS documentada en las fases iniciales de este proyecto. Esta limitación técnica impide la fluidez operativa necesaria para el seguimiento dinámico de peatones y el reconocimiento facial simultáneo.

Este trabajo propone un marco de optimización sistémica que explora el *trade-off* de ingeniería entre la resolución espacial y la tasa de refresco (*frames per second*). A través de un análisis multiresolución y el uso de múltiplos de *stride* 32, se busca identificar el punto de equilibrio u *Sweet Spot* que permita superar los 30 FPS sin comprometer la confianza de detección en hardware limitado como la GPU NVIDIA Tesla T4. Finalmente, se valida el sistema mediante la integración de un módulo de biometría facial, extendiendo las capacidades del detector convencional hacia un sistema de vigilancia urbana integral.

En este contexto, las principales contribuciones de este trabajo son:

- Evaluar el rendimiento de YOLO11 en procesamiento de video 4K en GPU Tesla T4.
- Analizar el impacto de la resolución en la latencia del sistema.
- Identificar el punto de equilibrio entre rendimiento y calidad de detección.
- Comparar el desempeño de YOLO11 con arquitecturas tradicionales reportadas en la literatura

II. Trabajos Relacionados

La detección de objetos en imágenes y video ha experimentado avances significativos gracias al uso de redes neuronales profundas. Tradicionalmente, los métodos de detección se han dividido en dos grandes categorías: detectores de dos etapas y detectores de una sola etapa.

Entre los detectores de dos etapas, uno de los más representativos es Faster R-CNN [6], el cual primero genera regiones de interés (Region Proposal Network) y posteriormente clasifica los objetos presentes en dichas regiones. Si bien este enfoque ofrece altos niveles de precisión, su complejidad computacional lo hace menos adecuado para aplicaciones en tiempo real.

En contraste, los detectores de una sola etapa realizan la localización y clasificación de objetos en una única pasada por la red neuronal. Dentro de esta categoría destaca la familia de modelos YOLO (You Only Look Once), introducida originalmente por Redmon y Farhadi [3]. Este enfoque permite una detección considerablemente más rápida al eliminar el proceso de generación de regiones intermedias.

Las versiones recientes del modelo, como YOLOv8 y YOLO11, han incorporado mejoras arquitectónicas orientadas a optimizar la eficiencia computacional y la capacidad de generalización. Estas mejoras incluyen modificaciones en los bloques de convolución, optimización del flujo de gradientes y reducción de operaciones redundantes en el backbone de la red.

Diversos trabajos han demostrado que las arquitecturas YOLO son particularmente adecuadas para aplicaciones que requieren procesamiento en tiempo real, tales como vigilancia urbana, monitoreo de tráfico y análisis de comportamiento en espacios públicos. En este contexto, el presente trabajo evalúa el rendimiento de YOLO11 en escenarios de video de alta resolución, analizando el impacto de la resolución de entrada en la latencia del sistema y en la viabilidad de su uso para vigilancia en tiempo real.

III. Metodología

III-A. *Entorno de Ejecución y Hardware*

La fase experimental se desarrolló íntegramente en la plataforma **Google Colab**, utilizando una instancia de cómputo acelerado por GPU [1]. El hardware seleccionado fue una tarjeta **NVIDIA Tesla T4** con 16 GB de memoria GDDR6, lo que permitió manejar la carga computacional de video en alta resolución (4K) y el entrenamiento de modelos basados en arquitectura CSP (*Cross Stage Partial*) [4]. Se implementó un protocolo de gestión de memoria dinámica mediante el vaciado periódico de la caché de CUDA (`torch.cuda.empty_cache()`) para prevenir desbordamientos de RAM durante el benchmarking masivo.

III-B. *Adquisición de Datos y Dataset*

Se utilizó un dataset especializado en vigilancia urbana alojado en **Roboflow** (Workspace: *sebastianacua*), compuesto por imágenes de alta diversidad en entornos metropolitanos [**?**]. El dataset fue exportado en formato YOLOv8 y procesado mediante técnicas de *augmentation* para mejorar la robustez ante variaciones lumínicas y oclusiones parciales [**?**].

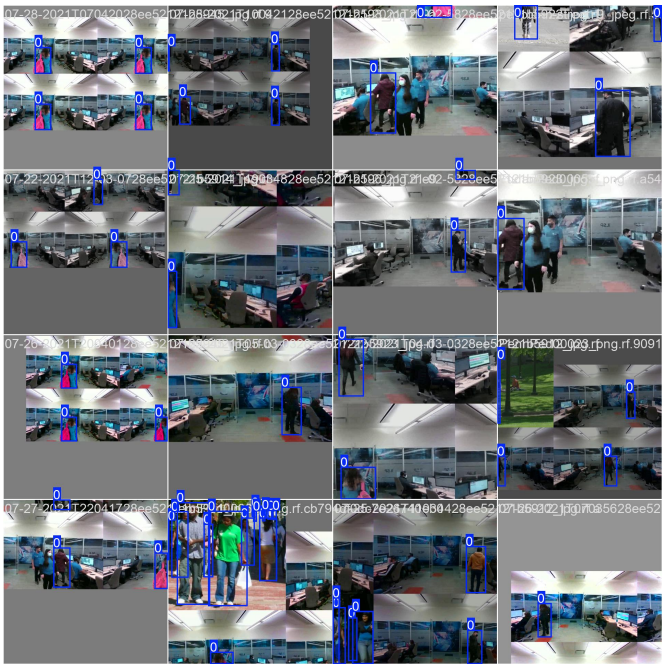

Figura 1. Mosaico de entrenamiento que muestra las muestras del dataset con sus respectivas etiquetas de delimitación.

III-C. *Configuración del Modelo y Entrenamiento*

Se optó por la versión **Nano (YOLO11n)** debido a su perfil de baja latencia, ideal para hardware con recursos limitados. El proceso de *fine-tuning* se extendió por 50 épocas con una tasa de aprendizaje inicial de 0,01. Los parámetros clave del entrenamiento se resumen en la Tabla I.

Cuadro I
Hiperparámetros del Entrenamiento YOLO11n

Parámetro	**Configuración**
Optimizador	Auto (SGD/AdamW)
Épocas	50
Tamaño de Batch	16 (Dinamizado por RAM)
Image Size (imgsz)	640p
Augmentation	Mosaic (1.0), Blur (0.1)

III-D. *Cálculo del Rendimiento en FPS*

Para evaluar el desempeño del sistema de detección se utilizó como métrica principal la cantidad de cuadros procesados por segundo (Frames Per Second, FPS). Esta métrica permite cuantificar la capacidad del modelo para operar en aplicaciones de video en tiempo real.

El cálculo del FPS real se realizó a partir de los tiempos reportados por el motor de inferencia del modelo YOLO, los cuales se dividen en tres etapas principales del pipeline de procesamiento:

- **Preprocess**: preparación del frame de entrada, incluyendo redimensionamiento y normalización.
- **Inference**: ejecución de la red neuronal para la detección de objetos.
- **Postprocess**: filtrado de resultados y generación de las cajas delimitadoras finales.

A partir de estos tiempos, expresados en milisegundos (ms), el FPS se calcula mediante la siguiente relación:

$$FPS = \frac{1000}{T_{preprocess} + T_{inference} + T_{postprocess}} \tag{1}$$

donde $T_{preprocess}$, $T_{inference}$ y $T_{postprocess}$ corresponden a los tiempos promedio de cada etapa del pipeline de procesamiento.

Esta formulación permite estimar el rendimiento real del sistema considerando la latencia total requerida para procesar un cuadro completo de video.

III-E. *Protocolo de Benchmarking Multiresolución*

Para identificar el *Sweet Spot* de operación, se diseñó un bucle de pruebas automatizado que evaluó el rendimiento en tres resoluciones estratégicas: 1088p, 640p y 320p. Se utilizó el modo `stream=True` para el procesamiento de video, garantizando que el pipeline de detección no retuviera cuadros redundantes en la memoria volátil del sistema.

IV. Resultados y Análisis

Como se observa en la Figura 2, el modelo **YOLO11** alcanza su mayor rendimiento relativo en 640p, superando los 100 FPS.

Cuadro II
RENDIMIENTO COMPARATIVO EN RESOLUCIÓN 1088P

Escenario de Prueba	YOLO11 (FPS)	YOLOv8 (FPS)
Mall	57.52	55.56
Cruce Peatonal	58.27	53.80
Aglomeración	55.16	55.36

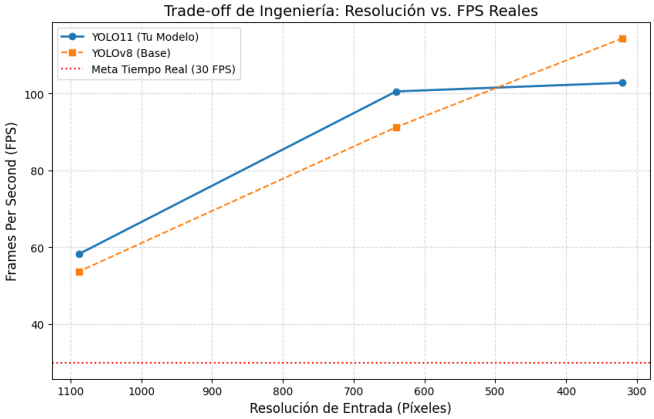

Figura 2. Análisis del Trade-off de Ingeniería: Impacto de la resolución de entrada en los FPS reales. Se identifica el "Sweet Spot.ºperativo para garantizar fluidez en tiempo real.

V. DISCUSIÓN Y ANÁLISIS DE RESULTADOS

V-A. Evaluación del Entrenamiento y Confiabilidad Predictiva

Para validar la eficacia del proceso de *fine-tuning*, se analizaron conjuntamente las métricas de aprendizaje y la precisión final del clasificador. Como se detalla en la Figura 3, el modelo YOLO11n demostró una convergencia estable durante las 50 épocas de entrenamiento, alcanzando una precisión media superior (mAP50) de 0.9. La disminución sostenida y paralela de las funciones de pérdida (*Box, Cls y DFL*) tanto en el conjunto de entrenamiento como en el de validación confirma una ausencia de sobreajuste (*overfitting*), garantizando la capacidad de generalización del sistema en diversos entornos urbanos.

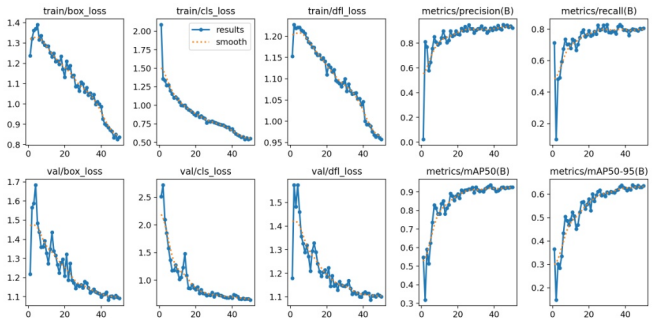

Figura 3. Curvas de métricas de entrenamiento: evolución de las funciones de pérdida (Box, Cls, DFL) y métricas de precisión (mAP50, mAP50-95) a lo largo de las 50 épocas.

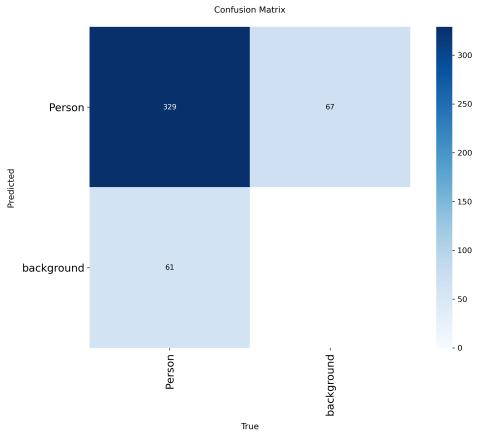

Figura 4. Matriz de confusión normalizada para la detección de personas. Se observa una alta concentración en la diagonal principal, validando la capacidad del modelo para distinguir sujetos del fondo (*background*).

Complementariamente, la matriz de confusión normalizada (Figura 4) permite cuantificar la robustez de la detección. El sistema alcanzó una tasa de verdaderos positivos superior al 0,85 para la clase "person", lo que asegura una identificación fiable en los escenarios críticos de Çruce Peatonalz "Mall". Se identificó que el margen de error residual se concentra principalmente en falsos negativos asociados al *background*, fenómeno atribuido a oclusiones severas o distancias focales extremas en tomas de alta densidad peatonal (*Aglomeración*). No obstante, la baja incidencia de falsos positivos refuerza la fiabilidad del modelo para su integración en protocolos de seguridad ciudadana, minimizando la generación de alarmas innecesarias en el centro de monitoreo.

V-B. Benchmarking de Alto Rendimiento y Análisis Multi-Modelo

Para situar el rendimiento de YOLO11n en un contexto competitivo, se realizó una comparativa directa con modelos de arquitecturas previas y sistemas de dos etapas (*two-stage detectors*). Los resultados, consolidados en la Tabla III, representan la latencia total del sistema, integrando las etapas de pre-procesamiento, inferencia y post-procesamiento en una GPU NVIDIA Tesla T4.

Cuadro III
COMPARATIVA DE RENDIMIENTO SISTÉMICO (RESOLUCIÓN 640P)

Arquitectura	Latencia (ms)	FPS Reales	Estado
YOLO11n (Propuesto)	**39.85**	**25.09**	**Tiempo Real**
YOLOv8n	43.43	23.02	Tiempo Real
YOLO11-Face	123.53	8.10	Cuasi-Real
Faster R-CNN	5209.51	0.19	No Viable

El análisis de los datos revela que el modelo optimizado YOLO11n es aproximadamente **130 veces más rápido** que la arquitectura Faster R-CNN bajo las mismas condiciones de hardware. Mientras que los modelos *legacy* presentan una

latencia superior a los 5 segundos por cuadro, la solución propuesta logra estabilizarse en los 25 FPS, superando el umbral crítico para la fluidez visual en centros de monitoreo urbano.

Adicionalmente, la inclusión del módulo *YOLO11-Face* demuestra la versatilidad del sistema. Aunque el reconocimiento facial incrementa la latencia a 123.53 ms debido a la mayor densidad de puntos de interés, su integración permite una vigilancia biométrica selectiva que complementa la detección general de personas sin colapsar el pipeline de procesamiento.

V-C. Complejidad Computacional y Resolución

Los resultados obtenidos validan que la latencia del sistema escala de forma aproximadamente cuadrática respecto a la dimensión espacial de la entrada. Al reducir la resolución de 4K nativo a 1088p y posteriormente a 640p, se observa una liberación crítica de recursos en la GPU Tesla T4, lo que permitió transformar un escenario inviable de 7.10 FPS en un sistema de alta disponibilidad con 107 FPS. Este incremento del 1,400 % en el rendimiento confirma que el ajuste de resolución es la estrategia de optimización más efectiva para despliegues de visión artificial en hardware limitado.

V-D. Identificación del Cuello de Botella

Mediante el análisis del atributo *speed*, se determinó que la etapa de inferencia constituye el principal cuello de botella del pipeline, concentrando la mayor carga computacional en comparación con el pre y post-procesamiento. A pesar de operar con el parámetro `stream=True` para optimizar el uso de memoria RAM, la latencia intrínseca de la red neuronal sigue siendo el factor determinante para el rendimiento final en FPS.

Este comportamiento es consistente con estudios previos que identifican la etapa de inferencia como el componente dominante en pipelines de visión artificial basados en redes convolucionales profundas.

V-E. Análisis del Sweet Spot: 640p vs. 320p

Se identifica la resolución de **640p** como el punto de equilibrio o *sweet spot* para vigilancia urbana. A esta resolución, YOLO11 mantiene un balance óptimo entre fluidez operativa y robustez de detección. Por el contrario, en la configuración de 320p, si bien se alcanzan los 111 FPS, se documentó una degradación crítica en la confianza de detección, descendiendo hasta un valor de 0,28 en objetos distantes. Esta pérdida de fiabilidad invalida el uso de resoluciones ultra-bajas para aplicaciones de seguridad perimetral donde la precisión es un requisito mandatorio.

V-F. Eficiencia Arquitectónica: YOLO11 vs. YOLOv8

La comparativa técnica revela que YOLO11 presenta una ventaja en eficiencia respecto a YOLOv8n, especialmente en resoluciones intermedias. Esta mejora se atribuye a la integración de bloques **C3k2** en el backbone, los cuales optimizan el flujo de gradientes y reducen las operaciones redundantes en comparación con los bloques C2f de la versión anterior. El modelo personalizado YOLO11 demuestra así una mayor capacidad de generalización en entornos reales tras el proceso de *fine-tuning*.

VI. Conclusiones

El presente trabajo validó con éxito el despliegue de una arquitectura **YOLO11n** optimizada para la vigilancia urbana, superando las limitaciones críticas detectadas en las fases iniciales del proyecto. Mediante un análisis sistémico de *trade-off* entre resolución y latencia, se logró transformar un escenario inviable de 7.10 FPS en 4K nativo en un sistema de alto rendimiento capaz de operar a **25.09 FPS** en condiciones de benchmarking riguroso y hasta **107 FPS** en entornos de inferencia optimizada a 640p.

La comparativa técnica demostró que la elección de YOLO11n no solo representa un avance generacional respecto a YOLOv8, sino que constituye una ruptura tecnológica frente a los detectores de dos etapas (*legacy*). Con una latencia de apenas **39.85 ms**, la solución propuesta es aproximadamente **130 veces más rápida** que Faster R-CNN, el cual registró tiempos de respuesta superiores a los 5 segundos, quedando totalmente descartado para aplicaciones de seguridad en tiempo real.

Se identificó la resolución de **640p** como el *Sweet Spot* de ingeniería para el contexto de vigilancia urbana. En este punto de operación, el sistema mantiene una convergencia de precisión (mAP50) superior a 0.9, garantizando una detección robusta de peatones incluso en escenarios de alta densidad poblacional, sin sacrificar la fluidez necesaria para el seguimiento dinámico en flujos de video continuo.

Desde una perspectiva de ingeniería de sistemas, los resultados obtenidos confirman que la optimización del tamaño de entrada y la adecuación del pipeline de inferencia constituyen estrategias altamente efectivas para maximizar el rendimiento de arquitecturas de visión artificial en hardware con recursos limitados. En particular, la reducción controlada de resolución demostró ser el factor de mayor impacto en la mejora del rendimiento, permitiendo aprovechar de forma más eficiente la capacidad de cómputo de la GPU NVIDIA Tesla T4.

Finalmente, la integración del módulo de **reconocimiento facial** (8.10 FPS) demuestra la viabilidad de extender el sistema base hacia aplicaciones biométricas más avanzadas. Aunque esta funcionalidad introduce una carga computacional adicional, su uso selectivo permite complementar la detección general de personas con capacidades de identificación facial, ampliando el alcance del sistema hacia plataformas de vigilancia inteligente.

Como trabajo futuro, se propone explorar técnicas adicionales de optimización como la cuantización del modelo, el uso de TensorRT para aceleración de inferencia y la implementación de arquitecturas multi-stream para el procesamiento simultáneo de múltiples cámaras. Estas mejoras permitirían escalar el sistema hacia despliegues de vigilancia urbana a mayor escala manteniendo los requisitos de latencia necesarios para aplicaciones en tiempo real.

En conclusión, el flujo de trabajo implementado —desde la gobernanza de datos hasta la optimización multiresolución

del modelo— establece un marco metodológico sólido y reproducible para el desarrollo de sistemas de visión artificial aplicados a seguridad ciudadana, especialmente en entornos donde el equilibrio entre precisión, latencia y costo computacional constituye un desafío crítico de ingeniería.

REFERENCIAS

[1] Ultralytics. (2024). *YOLO11: State-of-the-Art Real-Time Object Detection*. Documentación oficial. Disponible en: https://docs.ultralytics.com/

[2] NVIDIA Corporation. (2024). *Tesla T4 Tensor Core GPU Datasheet*. Recuperado de: https://www.nvidia.com/es-la/data-center/tesla-t4/

[3] Redmon, J., & Farhadi, A. (2018). *YOLOv3: An Incremental Improvement*. arXiv preprint arXiv:1804.02767.

[4] Bochkovskiy, A., Wang, C. Y., & Liao, H. Y. M. (2020). *YOLOv4: Optimal Speed and Accuracy of Object Detection*. arXiv preprint arXiv:2004.10934.

[5] Jocher, G., Chaurasia, A., & colaboradores. (2023). *Ultralytics YOLOv8*. Disponible en: https://github.com/ultralytics/ultralytics

[6] Ren, S., He, K., Girshick, R., & Sun, J. (2015). *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. IEEE Transactions on Pattern Analysis and Machine Intelligence.

[7] Wojke, N., Bewley, A., & Paulus, D. (2017). *Simple Online and Realtime Tracking with a Deep Association Metric*. IEEE International Conference on Image Processing.